CE-12: калібрування потужності та точності оцінювання

Аналіз чутливості експериментів двошарової СТМС

Claude Experiments Series

7 серпня 2026

Abstract

CE-12 є analysis-only дослідженням 40 парних порівнянь із CE-01 ($n = 100$, $T_{\text{end}} = 4000$) та CE-06 ($n = 60$, сценарій-залежні горизонти 3400–15000); нових траєкторій не моделювали. Для наперед заданої похибки 2.5% горизонту оцінений розмір вибірки для 80% потужності становить 194–264 у CE-01 та 10–528 у CE-06, тоді як для 10% горизонту відповідні діапазони зменшуються до 13–17 і 2–33. Отже, наявні вибірки добре підтримують твердження про похибки масштабу 5–10% у більшості режимів, але не дають рівномірної чутливості до 2.5%. У двох режимах CE-06 ($r = 2$, $k = 2$) додатково виявлено виразну розбіжність completion між Micro та Micro-Macro. Результати є plug-in калібруванням дисперсії для заданого margin, а не post hoc потужністю спостережуваного ефекту.

Contents

1 Статус і походження даних **2**

2 Наукове питання **2**

3 Дизайн та оцінювана величина **2**

4 Кількісні результати **3**
4.1 Розмір вибірки для 80% потужності 3
4.2 Емпірична потужність при наявному розмірі вибірки 3
4.3 Розбіжність completion 3
4.4 Графічне резюме 4

5 Аналіз та інтерпретація **4**

6 Значення для двошарової апроксимації та статті **4**

7 Обмеження і твердження, яких слід уникати **5**

8 Практичні рекомендації **5**

9 Відтворення **5**

1 Статус і походження даних

Аналіз завершено для 40 порівнянь. Вхідними даними були збережені термінальні часи прибуття CE-01 і всі комірки повної сітки CE-06. CE-01 має один горизонт $T_{\text{end}} = 4000$, а CE-06 використовує сценарій-залежні горизонти від 3400 до 15000. Тому абсолютні margins та сирі ΔRMST між комірками CE-06 не є однорідними величинами; нормування на власний горизонт є частиною дизайну.

Маніфест фіксує master seed, 500 bootstrap-перевибірок, формули, контрольні суми всіх джерел і трьох вихідних таблиць. Жодну симуляцію в межах CE-12 не запускали, тож цей звіт описує статистичну інформативність уже наявного дизайну, а не нову динамічну перевірку апроксимації.

2 Наукове питання

Основне питання: скільки парних реплікацій потрібно для виявлення наперед заданого зміщення двошарової апроксимації величиною 2.5%, 5% або 10% власного горизонту комірки? Додатково перевіряється, чи збігаються Full/Micro та MicroMacro за фактом досягнення термінального шару до T_{end}. Це питання про точність і статистичну чутливість, а не про швидкодію.

3 Дизайн та оцінювана величина

Для референсу X і варіанта Y визначено horizon-restricted часи

$$X^* = \begin{cases} X, & X \le T_{\text{end}}, \\ T_{\text{end}}, & X \text{ не спостережено до горизонту}, \end{cases}$$

$$Y^* = \begin{cases} Y, & Y \le T_{\text{end}}, \\ T_{\text{end}}, & Y \text{ не спостережено до горизонту}. \end{cases}$$

Парна різниця $D = Y^* - X^*$ має конвенцію

$$\Delta\text{RMST} = \text{RMST}_{\text{variant}} - \text{RMST}_{\text{reference}}.$$

Отже, $\Delta\text{RMST} < 0$ означає раніше прибуття варіанта. Цензуровані пари не вилучали, що запобігає селекції лише успішно завершених прогонів.

Нормальна plug-in формула підставляє спостережуване $\text{SD}(D)$, але ефект задає як signed margin $m \in \{0.025, 0.05, 0.10\}T_{\text{end}}$, а не як спостережуване $\bar{D}$. Емпіричну потужність отримано 500 bootstrap-перевибірками парних блоків після центрування D та зсуву на m. Тому оцінки в розд. 4 відповідають планованому масштабу ефекту, а не ймовірності повторити саме наявний point estimate.

4 Кількісні результати

4.1 Розмір вибірки для 80% потужності

Table 1: Діапазон парного N_{80} серед порівнянь. Margin визначено відносно власного T_{end} кожної комірки.

Джерело	Наявне n	Margin	Потрібний N_{80}
CE-01	100	2.5%	194–264
CE-01	100	5%	49–66
CE-01	100	10%	13–17
CE-06	60	2.5%	10–528
CE-06	60	5%	3–132
CE-06	60	10%	2–33

Широкий діапазон CE-06 у табл. 1 відображає режимну неоднорідність дисперсії парної похибки, а не лише різницю абсолютних margins.

4.2 Емпірична потужність при наявному розмірі вибірки

Table 2: Bootstrap-оцінка потужності при наявному розмірі вибірки. Тире означає вироджений наведений діапазон при потужності 1.000.

Джерело	Margin	Медіана	Діапазон
CE-01, $n = 100$	2.5%	0.494	0.420–0.546
CE-01, $n = 100$	5%	0.978	0.922–0.984
CE-01, $n = 100$	10%	1.000	—
CE-06, $n = 60$	2.5%	0.561	0.162–1.000
CE-06, $n = 60$	5%	0.987	0.480–1.000
CE-06, $n = 60$	10%	1.000	0.972–1.000

Медіани в табл. 2 не є гарантією для всієї сітки: при margin 5% найслабша комірка CE-06 має потужність лише 0.480.

4.3 Розбіжність completion

Table 3: Completion discordance у режимах CE-06 з $r = 2$ і $k = 2$. Різниця completion має знак MicroMacro мінус Micro.

Сценарій	Цензурування Micro	Comp. MM	Δcomp.	McNemar p
r2_d4_k2	30.0%	1.000	+0.300	0.00000763
r2_d6_k2	15.0%	1.000	+0.150	0.003906
r2_d10_k2	1.7%	1.000	+0.0167	1.000
r2_d20_k2	8.3%	1.000	+0.0833	0.0625

Дві перші комірки табл. 3 мають виразну незгоду completion за номінальним рівнем 0.05. Це окрема компонента апроксимаційної похибки, яку один ΔRMST не повністю описує.

4.4 Графічне резюме

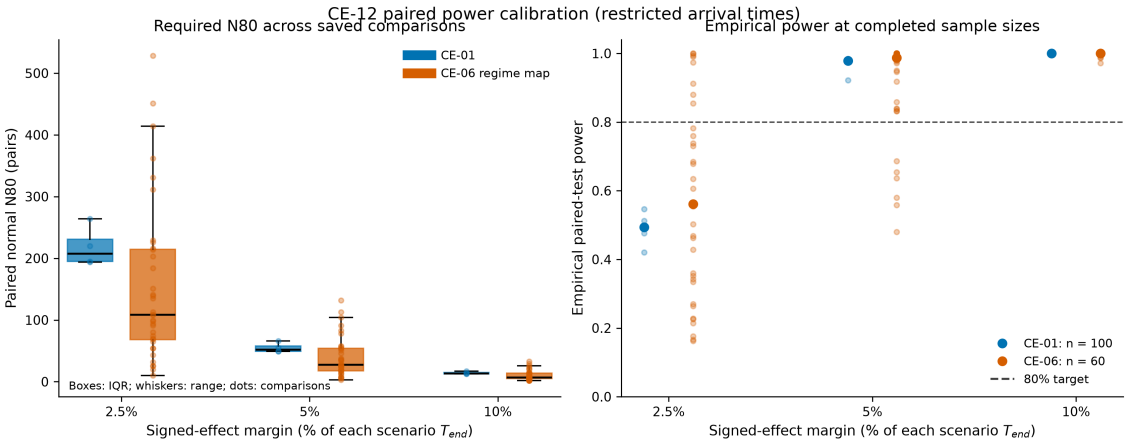


Figure 1: Калібрування потрібного розміру вибірки та емпіричної потужності за заданими margins; графік має читатися разом із сценарій-залежними горизонтами та completion diagnostics у табл. 3.

5 Аналіз та інтерпретація

Наявні 100 реплікацій CE-01 забезпечують високу чутливість до типового зміщення 5–10% горизонту, але для 2.5% усі plug-in N_{80} перевищують наявне n. У CE-06 навіть висока медіанна потужність не усуває слабких комірок: для найменшого margin N_{80} сягає 528.

Парування не є автоматично вигідним. Відношення потрібного непарного N_{80} на групу до парного N_{80} було меншим за 1 у 45 зі 120 рядків summary. Слабка або від'ємна коваріація між X^* та Y^* може збільшувати $\mathrm{Var}(D)$. Тому розмір вибірки слід планувати за конкретним режимом, а не за глобальним припущенням про користь парування.

Рис. 1 та табл. 3 разом показують дві різні вимоги: достатню точність часової метрики й здатність виявити якісну незгоду щодо досягнення кінцевого шару. CE-12 не встановлює механістичну причину похибки; він калібрує статистичну спроможність її виміряти.

6 Значення для двошарової апроксимації та статті

- Твердження про "малу похибку" потребує наперед визначеного margin; відсутність значущості не доводить еквівалентності.
- Дані краще підтримують ефекти 5–10% горизонту, ніж точність у межах 2.5% у кожному режимі.
- За цензурування слід спільно подавати ΔRMST, completion, Δcompletion і survival/CDF curves.
- Додаткові реплікації слід спрямовувати на комірки з найбільшою дисперсією або completion discordance, а не розподіляти рівномірно.

7 Обмеження і твердження, яких слід уникати

1. Plug-in аналіз не враховує невизначеність оціненої дисперсії.
2. Нормальна апроксимація для рекомендованих $N < 20$–30 ненадійна; такі значення є лише грубими орієнтирами.
3. 500 bootstrap-перевибірок створюють Monte Carlo похибку, особливо поблизу порогового рівня потужності.
4. Корекцію на множинність для 40 порівнянь не застосовано. Окреме $p < 0.05$ не підтверджує сітково-глобальну гіпотезу.
5. Не слід називати ці результати потужністю для спостережуваного ефекту: signed effect штучно задано рівним margin.
6. Абсолютні margins і ΔRMST не можна безпосередньо порівнювати між різними горизонтами.

8 Практичні рекомендації

1. До підтверджувального запуску зафіксувати науково значущі margins.
2. Збільшити n для CE-01 при 2.5% та для найслабших комірок CE-06.
3. Для малого N застосувати simulation-based calibration або перевірку стійкості до ненормальності.
4. Для completion diagnostics визначити первинні контрасти й правило множинної корекції до аналізу.

9 Відтворення

Analysis runner: `extrascripts/run_ce12_power_calibration.py`. Основні результати:
`output/claude_experiments/ce12_power_calibration/power_summary.csv`,
`output/claude_experiments/ce12_power_calibration/empirical_power.csv`,
`output/claude_experiments/ce12_power_calibration/completion_discordance.csv`. Формули, seed `812120026`, SHA-256 джерел і статус analysis-only: `output/claude_experiments/ce12_power_calibration/manifest.json`. Джерела: `output/ablation_hazard_placement/final_100/arrival_times.csv` та `output/claude_experiments/ce06_regime_map_full/cells/`.