Довідник метрик: як порівнювати MicroMacro та Full Micro

Які метрики коректні, які оманливі, і чому

Two-Scale CTMC Project

31 липня 2026

Abstract

Цей документ пояснює повну ієрархію метрик порівняння, що використовуються в проєкті, демонструє математичний механізм кожної з них і визначає, які метрики валідні за censoring, а які вносять систематичний bias. Центральне повідомлення: **conditional mean та conditional median (лише завершені прогони) є зміщеними щоразу, коли дві моделі мають різні completion rates. RMST — коректна первинна метрика.** Усі приклади використовують реальні дані з каліброваного бенчмарку chain-of-cliques та з експерименту абляції CE-01.

Contents

1 Ядро проблеми порівняння **2**

2 Аналіз відмінностей методів: дизайн перед метриками **2**
2.1 Спершу вирішіть, яке питання ви ставите 2
2.2 Принцип ізоляції 3
2.3 Передумова 1: звітуйте completion, потім використовуйте censoring-aware оцінювачі 3
2.4 Передумова 2: сумірність горизонтів 3
2.5 Оберіть нормалізацію, незалежну від ефекту 3
2.6 Відокремте систематичний сигнал від стохастичного шуму 4
2.7 Атрибуція механізму: ablation ladder 4
2.8 Від атрибуції до розгортуваного параметричного сурогату 4
2.9 Розкрийте калібрування 4
2.10 Включіть negative control 5
2.11 Чекліст 5

3 Каталог метрик **6**
3.1 Completion Rate 6
3.2 Conditional Mean та Median (лише завершені прогони) 6
3.3 Restricted Mean Survival Time (RMST) 7
3.4 Відстань Wasserstein-1 (W_1) 8
3.5 Статистика Kolmogorov–Smirnov 8
3.6 Per-Hop метрики часу прибуття: $W_1(T_i)$ та парна похибка 9

4 Графік $I_{tot}(t)$: phase noise проти похибки апроксимації **9**

5 Ієрархія метрик та рекомендації **10**

6 Розібраний приклад: абляція CE-01 **11**

7 Статистична потужність та обсяг вибірки **11**

8 Підсумок **12**

1 Ядро проблеми порівняння

Ми порівнюємо два симулятори на одній і тій самій стохастичній епідемічній моделі:

- **Full Micro**: точний Gillespie CTMC на повній мережі. Ground truth.
- **MicroMacro (MM)**: двомасштабна апроксимація. Використовує агрегований macro hazard $\lambda_{ij} = \beta W_{ij} \bar{i}_i \bar{s}_j$ для інтеркомунітарних передач.

Ключова величина — T_{last}: час, коли епідемія вперше досягає останньої громади. У кожній реплікації симуляція йде до T_{end}; якщо прибуття до того моменту не сталося, T_{last} є censored (невідоме, відомо лише що воно $> T_{\text{end}}$).

Фундаментальна складність: **дві моделі зазвичай мають різні completion rates** (частка реплікацій, де $T_{\text{last}} < T_{\text{end}}$), бо MM поширюється в середньому швидше за Micro через Jensen-ефект.

2 Аналіз відмінностей методів: дизайн перед метриками

Метрика має сенс лише всередині дизайну порівняння. Повторюваний режим збою в цьому проєкті — не вибір неправильної формули, а вимога до метрики відповісти на питання, на яке вона не може відповісти, або читання числа, що мовчки змішує ефект інтересу з confounder. Цей розділ формулює принципи, що мають керувати будь-яким порівнянням Micro-vs-MM. Каталог метрик (розділ 3) тоді — це просто набір інструментів, що використовується всередині цих принципів, а не їх замінник.

2.1 Спершу вирішіть, яке питання ви ставите

Три питання виглядають схоже, але вимагають різних дизайнів і дозволяють різні висновки:

Q1 — Існування. Чи взагалі MM відрізняється від Micro, поза Monte-Carlo шумом? → значущість ΔRMST (bootstrap CI) або двовибірковий тест розподілів. Потребує достатнього N; більше нічого.

Q2 — Магнітуда і знак. У якому напрямі й наскільки? → ΔRMST та його horizon-нормована форма, плюс completion gap. Потребує censoring-aware оцінювачів і фіксованого горизонту.

Q3 — Механізм / атрибуція. Чому виникає різниця, і яка властивість мережі її контролює? → контрольована абляція, що перемикає одну апроксимацію за раз, плюс сурогатний параметричний тест. Потребує ізоляції confounders, а не лише великого ефекту.

Центральна методологічна помилка — відповідати на **Q3 експериментом Q2**: звітувати про великий, неконтрольований ΔRMST і наративно приписувати механізм (“premature leakage”), який дизайн ніколи не ізолював. Магнітуда — це не механізм, а знак, що змінюється між сценаріями (як у β-ratio sweep), є свідченням того, що число визначають confounders, а не названий механізм.

2.2 Принцип ізоляції

Щоб приписати різницю причині, кожна інша причина має бути зафіксована. Конкретно:

- **Paired seeds.** Запускати Micro і кожен варіант MM на тій самій реалізації мережі й тому самому RNG-потоці micro layer. Парна різниця $\delta_r = T_r^{MM} - T_r^{Micro}$ тоді усуває between-run дисперсію, яка інакше домінує в CI. CE-01 робить це; chain-of-cliques sweep — ні.
- **По одному фактору за раз — для атрибуції.** Щоб приписати похибку механізму, використовуйте ablation ladder (розділ 2.7), що перемикає одну апроксимацію на щабель. Щоб відобразити параметричну залежність, варіюйте параметри на сітці, але записуйте кожну коваріату, щоб її ефект можна було зрегресувати; ніколи не читайте одиничний one-factor sweep як каузальний.
- **Сумірні умови.** Два сценарії порівнянні лише якщо їх горизонт і completion regime збігаються (розділи 2.3, 2.4). Інакше числа не лежать на одній осі.

2.3 Передумова 1: звітуйте completion, потім використовуйте censoring-aware оцінювачі

Звітуйте p_{Micro}, p_{MM} та їх gap перед будь-яким числом часу прибуття. Щойно gap перевищує ≈ 5–10%, кожна completed-runs-only метрика — conditional mean, conditional median, W_1, KS — зазнає selection-bias і не має нести headline (розділ 3.2 показує, як це дає неправильний знак). Використовуйте RMST / survival curves, які включають цензуровані прогони на їх відомій нижній межі. Коли горизонти не можна зіставити, поверніться до Kaplan–Meier survival порівняння або re-truncate обидві моделі до спільного completion level перед порівнянням.

2.4 Передумова 2: сумірність горизонтів

RMST залежить від T_{end}, тож сирий ΔRMST має сенс лише всередині фіксованого горизонту. β-ratio sweep використовував $T_{\text{end}} \in [2000, 20000]$; порівняння його сирих зсувів по r порівнює різні осі, і виживають лише знак та horizon-нормовані величини. Правило: всередині сценарію звітуйте сирий зсув; між сценаріями звітуйте $\Delta\text{RMST}/T_{\text{end}}$, rel-$W_1$ або completion-probability gap $\Delta p = p_{\text{MM}} - p_{\text{Micro}}$.

2.5 Оберіть нормалізацію, незалежну від ефекту

rel-$W_1 = W_1/\mathbb{E}[T^{Micro}]$ ділить на величину, що лежить на тій самій часовій шкалі, що й чисельник, тож вона зменшує великі абсолютні похибки “безкоштовно”: довший ланцюг роздуває знаменник так само швидко, як і чисельник, і 3.5% можуть виглядати заспокійливо за побудовою. Завжди доповнюйте її шкалою, незалежною від середнього:

$$\frac{W_1}{\text{IQR}(T^{Micro})} \qquad \text{або} \qquad \frac{W_1}{\Delta T_{\text{hop}}}, \quad \Delta T_{\text{hop}} = \frac{\mathbb{E}[T_{\text{last}}]}{L-1}.$$

W_1, що становить 3.5% середнього, але 40% одного per-hop приросту, не є малим у жодному операційно релевантному сенсі.

2.6 Відокремте систематичний сигнал від стохастичного шуму

Between-run (phase) шум домінує в неспарених порівняннях і в поточковій $I_{\text{tot}}(t)$ смузі. Наслідки:

- Надавайте перевагу парному δ_i для Q1/Q3: він вимірює лише похибку апроксимації для спільної реалізації, усуваючи phase noise.
- Читайте IQR $I_{\text{tot}}(t)$ як "наскільки мінлива епідемія", а не "наскільки зміщений MM" (розділ 4).
- Широка смуга навколо двох майже збіжних медіан не є свідченням великої похибки апроксимації.

2.7 Атрибуція механізму: ablation ladder

Атрибуція потребує драбини, кожен щабель якої перемикає рівно одну апроксимацію, тож приріст ΔRMST між сусідніми щаблями зараховується цій одній зміні:

Rung	Hazard × Placement	Що ізолює приріст
Full Micro	exact / exact	ground truth ($\Delta\text{RMST} = 0$)
Oracle E/E	exact / exact-target	лише numerical/synchronisation
Oracle E/U	exact / uniform	**import placement** error
Aggregate A/B	aggregate / boundary	**rate abstraction** error
MicroMacro A/U	aggregate / uniform	placement + rate (deployed model)

CE-01, проведений так, приписує основну частину похибки rate abstraction, а placement значущий лише за точного hazard. **Застереження:** oracle-щаблі читають точний список ребер і стани вузлів; вони є діагностичними верхніми межами, а не розгортуваними моделями — реальний MM може знати лише агреговані параметри, ніколи точну структуру.

2.8 Від атрибуції до розгортуваного параметричного сурогату

Щойно драбина локалізує похибку до конкретної апроксимації, розгортуване питання полягає в тому, чи може функція від відомих параметрів — spectral gap λ_2, середній ступінь, boundary-degree статистики — відтворити oracle-корекцію без точної структури. Коректний тест — не "чи корелює похибка з λ_2 по мережах" (ця кореляція сконфаунджена всім, що ко-варіює з λ_2). Він такий: чи переміщує впорскування сурогата MM вгору по драбині до oracle-щабля, за всіх інших факторів фіксованих? Щоб це підтримати, параметричний sweep має записувати λ_2, ступінь, boundary статистики та горизонт на реалізацію, щоб сурогат можна було підігнати й валідувати out-of-sample, а не підганяти до тих самих corner cases, що його мотивували.

2.9 Розкрийте калібрування

Кожне поточне число bias припускає $\beta_{\text{macro}} = \beta$ та $W_{ij} = k$, встановлені by fiat. Частина ΔRMST тоді усувна підбором λ_{ij} (calibration error), а частина невіддільна за лише агрегованого стану (structural error). Звітуйте oracle-калібрований зсув як structural floor і маркуйте кожне некаліброване число як таке; інакше читач не може відрізнити властивість методу від артефакту довільного вибору.

2.10 Включіть negative control

Достовірний аналіз різниці показує ефект зникаючим там, де теорія каже, що він має зникнути. Топологія clique–bridge–leaf ($n = 100$, $k = 2$) є confounder-free контролем; звітуйте її W_1 і KS з числами, навіть коли null. Ефект, що кількісно визначений лише в corner cases (мале k, повільне поширення, велике β_{out}) і залишений якісним у чистому випадку, ще не встановлений.

2.11 Чекліст

1. Сформулюйте питання: Q1, Q2 чи Q3. Узгодьте дизайн із ним.
2. Спершу звітуйте completion; якщо gap $> 10\%$, приберіть completed-only метрики з headline.
3. Фіксуйте горизонт усередині порівняння; нормалізуйте (і розкривайте T_{end}) між порівняннями.
4. Додайте effect-independent нормалізацію поряд із rel-W_1.
5. Використовуйте paired seeds і парний δ_i, щоб зняти phase noise.
6. Для тверджень про механізм показуйте ablation ladder, а не один великий зсув.
7. Для тверджень про параметри фіксуйте коваріати або регресуйте їх, і валідуйте сурогат out-of-sample.
8. Розкривайте калібрування; відокремлюйте structural від calibration error.
9. Включайте negative control з числами.

Pitfall	**Коректна практика**
Conditional mean/median за нерівних completion	Звітуйте completion; використовуйте RMST / survival (розд. 2.3)
Сирий ΔRMST порівняний за різних T_{end}	Нормалізуйте cross-scenario; сирий лише в межах горизонту (розд. 2.4)
rel-W_1 прочитаний як “малий” сам по собі	Додайте W_1/IQR або $W_1/\Delta T_{\text{hop}}$ (розд. 2.5)
Механізм наративований з одного великого зсуву	Ablation ladder, один toggle на щабель (розд. 2.7)
Похибка “пояснена” кореляцією з λ_2	Фіксуйте коваріати / регресуйте; валідуйте сурогат (розд. 2.8)
Числа bias з $\beta_{\text{macro}} = \beta$ без маркування	Звітуйте structural floor; маркуйте uncalibrated (розд. 2.9)
Чистий випадок залишено якісним	Negative control з числами W_1/KS (розд. 2.10)

Table 1: Відображення поширених пасток аналізу на відповідний принцип.

3 Каталог метрик

3.1 Completion Rate

$$p_{\text{complete}} = \frac{\#\{T_{\text{last}} < T_{\text{end}}\}}{N}$$

Що вимірює: чи проходить епідемія весь ланцюг у межах горизонту симуляції. Залежить як від внутрішньої стохастичності епідемії, так і від bias апроксимації MM.

Приклад (clique baseline, 100 reps):

$$p_{\text{Micro}} = 0.68, \quad p_{\text{MM}} = 0.82.$$

MM завершує на 14% більше прогонів — прямий доказ, що MM поширюється швидше в середньому.

Коректне використання: Звітуйте першим. Великий gap ($|p_{\text{MM}} - p_{\text{Micro}}| > 0.1$) вже інформативний і означає, що всі інші completed-run метрики будуть зміщеними (див. розділ 3.2).

Обмеження: Це один бінарний поріг; він не квантифікує, наскільки швидше чи повільніше.

3.2 Conditional Mean та Median (лише завершені прогони)

$$\hat{\mu}^{\text{cond}} = \frac{1}{|\mathcal{C}|} \sum_{r \in \mathcal{C}} T_r, \quad \mathcal{C} = \{r : T_r < T_{\text{end}}\}.$$

Що вимірює: середній (або медіанний) час прибуття серед прогонів, що випадково завершилися.

Чому воно зміщене, коли completion rates відрізняються. Припустимо, Jensen виконується: $F^{MM}(t) \geq F^{Micro}(t)$ для всіх t (MM стохастично швидший, прибуває раніше). Conditional median є

$$m^{Micro} = F^{-1}(0.5 \cdot p_{\text{Micro}}) = F^{-1}(0.34), \quad m^{MM} = F^{-1}(0.5 \cdot p_{\text{MM}}) = F^{-1}(0.41).$$

Ми порівнюємо m^{MM} з m^{Micro}, але вони відповідають різним перцентилям безумовного розподілу (41-й проти 34-го). Навіть коли $F^{MM}(t) \geq F^{Micro}(t)$, 41-й перцентиль Micro може легко перевищити 41-й перцентиль MM, роблячи $m^{MM} > m^{Micro}$ — протилежне до того, що ми очікуємо.

Конкретний приклад. Clique baseline, 100 reps:

$$m^{Micro}_{\text{cond}} = 1949.4, \quad m^{MM}_{\text{cond}} = 2020.2, \quad \text{shift} = +70.8 \quad \text{(MM здається пізнішим!)}.$$

Але censoring-коректний RMST shift дорівнює -75.6 (MM раніший). $+70.8$ — це артефакт: додаткові 14% completions MM — це повільні прогони поблизу $T_{\text{end}} = 2500$, що тягнуть conditional median MM угору.

Вирок: не використовуйте conditional mean чи median як первинну метрику, коли completion rates відрізняються. Вони можуть показати неправильний знак.

3.3 Restricted Mean Survival Time (RMST)

$$\text{RMST} = \mathbb{E}[\min(T_{\text{last}}, T_{\text{end}})] = \int_0^{T_{\text{end}}} P(T_{\text{last}} > t)\, dt.$$

Що вимірює: очікуваний час до прибуття, обмежений зверху T_{end}. Цензуровані прогони дають внесок T_{end} (їх нижню межу), тож усі прогони включені без відкидання інформації. Еквівалентно, RMST — це площа під survival curve $S(t) = P(T_{\text{last}} > t)$ від 0 до T_{end}.

Чому воно коректно обробляє censoring. Для цензурованого прогону ($T_r > T_{\text{end}}$) ми знаємо, що справжній час прибуття щонайменше T_{end}. Використання $\min(T_r, T_{\text{end}}) = T_{\text{end}}$ як внеску — це коректний likelihood-consistent вибір для right-censored спостереження.

Знаковий зсув:

$$\Delta\text{RMST} = \text{RMST}^{MM} - \text{RMST}^{Micro}.$$

- $\Delta\text{RMST} < 0$: MM прибуває раніше (передчасна пропагація).
- $\Delta\text{RMST} > 0$: MM прибуває пізніше (надмірно консервативний).
- $\Delta\text{RMST} = 0$: немає систематичного bias на обраному горизонті.

Зв'язок із Jensen. Нерівність Jensen передбачає $S^{Micro}(t) \geq S^{Macro}(t)$ для всіх t, звідки $\Delta\text{RMST} \leq 0$: інтегрування нерівності survival дає $\text{RMST}^{MM} \leq \text{RMST}^{Micro}$. RMST тому є коректною метрикою для перевірки Jensen-прогнозу.

Як RMST обчислюється в цьому проєкті (код). З `extrascripts/benchmark_censoring_`

```
restricted_micro = np.where(np.isfinite(micro), micro, horizon)
restricted_macro = np.where(np.isfinite(macro), macro, horizon)
rmst_shift = np.mean(restricted_macro - restricted_micro)
```

Цензуровані прогони ($T_r = \text{NaN}$ або ∞) замінюються на `horizon` (T_{end}), потім зсув — це середнє попарних різниць по всіх N реплікаціях. Це еквівалентно різниці площ між survival curves, оціненими емпіричним CDF.

Bootstrap довірчий інтервал. CI отримується ресемплінгом повної таблиці пар (T_r^{Micro}, T_r^{MM}) (включно з цензурованими рядками) із заміщенням, 1000 разів. Пари ресемплюються спільно (не незалежно), щоб зберегти within-run кореляції, якщо дві моделі поділяють random seed.

Конкретні числа (калібрований clique benchmark, 100 reps):

Scenario	RMST^{Micro}	RMST^{MM}	ΔRMST	95% CI
baseline $k = 5$	2089.3	2013.6	-75.6	$[-197.3,\ +34.8]$
$k = 10$	1326.0	1198.1	-127.9	$[-217.8,\ -\mathbf{39.7}]$
$k = 20$	879.5	738.7	-140.8	$[-190.6,\ -\mathbf{89.4}]$
$L = 15$	3342.1	3093.7	-248.4	$[-428.7,\ -\mathbf{51.2}]$
sparse baseline	2869.4	1640.5	-1228.9	$[-1379.4,\ -\mathbf{1089.6}]$

Усі сценарії з достатнім completion показують $\Delta\text{RMST} < 0$ (жирне CI = значуще). CI baseline $k = 5$ включає нуль: не тому, що Jensen хибний, а тому, що 100 реплікацій недостатньо (SE ≈ 87, зсув ≈ 0.87 SE).

Обмеження: RMST залежить від T_{end}. Довший горизонт робить RMST чутливішим до повільно-завершуваних прогонів. Завжди звітуйте горизонт поряд із RMST.

3.4 Відстань Wasserstein-1 (W_1)

$$W_1(P,Q) = \int_{-\infty}^{\infty} |F_P(t) - F_Q(t)|\, dt = \int_0^1 |F_P^{-1}(u) - F_Q^{-1}(u)|\, du.$$

Що вимірює: середню абсолютну різницю між quantile functions двох розподілів. Еквівалентно, мінімальну очікувану відстань, потрібну, щоб "перевезти" масу розподілу P на Q.

Relative W_1:

$$\text{rel-}W_1 = \frac{W_1}{\mathbb{E}[T^{Micro}]}.$$

Це нормалізує на середнє Micro, даючи безрозмірну міру розбіжності розподілів.

Як воно використовується в цьому проєкті. W_1 обчислюється лише на **завершених** прогонах. Тому воно зазнає того самого censoring bias, що й conditional mean, коли completion rates відрізняються. Воно відповідає: "Серед прогонів, які обидві моделі завершили, наскільки різними є розподіли часу прибуття?" Це валідно для порівняння форми розподілу, але не вловлює ефекту "MM завершує більше прогонів".

Конкретні числа:

Scenario	W_1	rel-W_1	Note
clique baseline $k = 5$	67.0	3.5%	малий, CI incl. zero
clique $k = 10$	130.1	9.8%	помірний
clique $k = 20$	140.8	16.0%	зростає з k
sparse baseline	—	42.6%	величезний; 99% vs 100% complete

Обмеження: W_1 на завершених прогонах зміщений, коли completion rates відрізняються. Для sparse $k = 1$ сценарію Micro завершує лише 2%, а MM завершує 19%; W_1 не звітується, бо два підмножини не порівнянні.

Коли надавати перевагу W_1 над RMST:

- Коли обидві моделі мають 100% completion (без censoring): W_1 і RMST дають узгоджену інформацію; W_1 чутливіший до відмінностей хвостів.
- Коли ви хочете порівняти форму розподілу (не лише середнє): W_1 вловлює quantile-by-quantile відмінності, а не лише середнє.
- **Не** як первинну метрику, коли completion rates відрізняються.

3.5 Статистика Kolmogorov–Smirnov

$$D_{\text{KS}} = \sup_t |F^{Micro}(t) - F^{MM}(t)|.$$

Що вимірює: максимальну вертикальну відстань між двома CDF. Асоційоване p-значення перевіряє, чи могли дві вибірки походити з одного розподілу.

Обмеження: KS — це якісний тест (чи є різниця?), а не кількісна міра (наскільки велика різниця?). Він також обчислюється лише на завершених прогонах. У цьому проєкті він використовується як consistency check, а не первинна метрика.

3.6 Per-Hop метрики часу прибуття: $W_1(T_i)$ та парна похибка

Усі метрики вище оперують на термінальному часі прибуття T_{last}. Per-hop аналіз розкладає похибку шар за шаром.

Per-hop Wasserstein $W_1(T_i)$: Обчисліть відстань W_1 між розподілом часів прибуття T_i^{Micro} та T_i^{MM} для громади $i = 0, \ldots, L-1$ (по всіх реплікаціях, що досягли громади i). Це відповідає: "Де в ланцюзі пікує розподільна похибка?"

Парна кумулятивна похибка:

$$\delta_i = T_i^{MM} - T_i^{Micro} \quad \text{(та сама реплікація)}.$$

Це обчислюється лише для прогонів, де обидві моделі досягли громади i (парне спостереження). Використовуючи той самий random seed, within-run кореляції зберігаються, і оцінювач має значно нижчу дисперсію, ніж between-run порівняння.

Чому парна похибка — найчутливіша метрика. Оскільки between-run мінливість домінує в невизначеності RMST, парне порівняння усуває її повністю: кожен δ_i вимірює лише похибку апроксимації для того прогону, а не природну стохастичну мінливість. Ціна — censoring: на останній громаді ($i = 9$) з 68% Micro completion існує лише 68 пар, а відсутні 32 — це найповільніші прогони Micro — саме ті з найбільшим $|\delta_i|$.

Приклад (калібрований clique baseline): Медіанна парна похибка на шарі 7 становить ≈ -200 (MM прибуває на 200 одиниць часу раніше); на шарі 9 вона повертається до 0 через censoring повільних прогонів Micro. IQR становить ± 400 — велика, бо кожен прогін зазнає різної локальної динаміки.

4 Графік $I_{\text{tot}}(t)$: phase noise проти похибки апроксимації

Загальна кількість інфікованих у момент t:

$$I_{\text{tot}}(t) = \sum_{c=0}^{L-1} I_c(t).$$

У постановці chain-of-cliques з $n = 100$ вузлами на громаду, I_{tot} приблизно є східчастою функцією: кожна громада дає sigmoid-крок висоти n.

Що насправді вимірює IQR-смуга на $I_{\text{tot}}(t)$. У фіксований момент t поточковий IQR по реплікаціях відображає:

1. **Phase noise** ($\approx 90\%$ ширини): природну мінливість у тому, скільки громад інфіковано до моменту t. Різні прогони на різних "сходинках" драбини.
2. **Похибку апроксимації** ($\approx 10\%$ ширини): систематичну різницю між Micro та MM у тому, наскільки швидко інфікуються громади.

Оскільки phase noise домінує в ширині IQR, силует $I_{\text{tot}}(t)$ — **не корисна міра якості апроксимації**. Порівняння ширин IQR-смуг Micro та MM говорить про природну мінливість епідемії, а не про bias MM.

Коли графік $I_{\text{tot}}(t)$ корисний.

- **Sanity check**: якщо дві медіани драматично різні (як у sparse baseline: $\Delta I \approx 400$ при $t = 1500$), це прямий доказ великого bias.

- **Якісна ідентифікація режиму**: східчаста структура показує, скільки громад зазвичай інфіковано в кожен момент.
- **Не для**: квантифікації малих-до-помірних bias (clique case), чи порівняння форм розподілів.

5 Ієрархія метрик та рекомендації

Metric	**Обробляє censoring?**	**Використовувати коли**	**Не використовувати коли**
Completion rate	n/a	Завжди звітувати першим	—
RMST / ΔRMST	**Так**	Первинна метрика; завжди валідна	—
$W_1(T_{\text{last}})$	Ні	Обидві моделі $\approx 100\%$ complete	Completion rates різняться $> 5\%$
Cond. mean shift	Ні	Completion rates $\approx$ рівні	Completion rates різняться
Cond. median shift	Ні	Completion rates $\approx$ рівні	Completion rates різняться
Paired δ_i	Частково	Чутливе виявлення похибки per hop	Останній шар (censoring повільних прогонів)
$W_1(T_i)$ per hop	Ні	Зростання похибки крізь ланцюг	Перший/останній шари з малим completion
$I_{\text{tot}}(t)$	n/a	Ідентифікація режиму, sanity check	Квантифікація похибки апроксимації
KS statistic	Ні	Лише якісний тест	Первинне кількісне порівняння

Table 2: Ієрархія метрик. **Жирне**: рекомендована первинна метрика.

Рекомендований порядок звітування для кожного сценарію.

1. Completion rates p_{Micro}, p_{MM} та їх різниця.
2. ΔRMST з 95% bootstrap CI. Використовуйте це для перевірки Jensen і для оцінки практичного bias.
3. rel-$W_1(T_{\text{last}})$ лише якщо обидва completion rates ≥ 0.9. Дає інформацію про форму розподілу поза середнім.
4. Per-hop парна похибка δ_i: медіана та IQR по реплікаціях. Для визначення, де в ланцюзі накопичується похибка.
5. Медіана $I_{\text{tot}}(t)$: лише для візуального контексту, не для кількісних висновків.

6 Розібраний приклад: абляція CE-01

CE-01 використовує 100 парних реплікацій (та сама мережа й seed для всіх варіантів); $T_{\text{end}} = 4000$; усі п'ять варіантів завершують 100% прогонів (без censoring). Це ідеальна постановка: усі метрики валідні.

Таблиця первинних результатів.

Variant	Completion	$\mathbb{E}[T_{\text{last}}]$	ΔRMST	95% CI
Full Micro	1.00	2936.7	0	—
Oracle E/E	1.00	2944.3	$+7.5$	$[-93.6,\ +120.3]$
Oracle E/U	1.00	2775.5	-161.2	$[-266.8,\ -48.8]$
Aggregate A/B	1.00	2735.5	-201.2	$[-302.4,\ -106.7]$
MicroMacro (A/U)	1.00	2715.9	-220.8	$[-307.9,\ -120.2]$

Оскільки всі варіанти завершують 100% прогонів і поділяють ті самі seeds, $\Delta\text{RMST} = \mathbb{E}[T^{\text{variant}}] - \mathbb{E}[T^{Micro}]$ точно (без censoring, без between-run confounding). Conditional mean та RMST тут ідентичні.

Чому RMST усе одно має значення навіть за 100% completion. Формулювання RMST чисто узагальнюється на цензурований випадок. Використання RMST усюди — навіть коли воно зводиться до звичайного середнього — забезпечує той самий код і ту саму інтерпретацію в усіх експериментах. Це уникає введення окремих code paths, що могли б мовчки обчислити неправильне, коли деякі прогони цензуровані.

7 Статистична потужність та обсяг вибірки

Поширене питання: скільки реплікацій потрібно, щоб виявити заданий ΔRMST з 80% потужністю на 5% рівні значущості?

Для одновибіркового t-тесту на $\Delta_r = \min(T_r^{MM}, T_{\text{end}}) - \min(T_r^{Micro}, T_{\text{end}})$ зі стандартним відхиленням σ_Δ:

$$N \approx \left(\frac{(z_{0.025} + z_{0.20})\,\sigma_\Delta}{\delta} \right)^2 = \left(\frac{2.80\,\sigma_\Delta}{\delta} \right)^2,$$

де $\delta = |\Delta\text{RMST}|$ — цільовий розмір ефекту.

Калібрований clique baseline ($k = 5$). 3 bootstrap: $\sigma_\Delta \approx 590$ (std попарних різниць), $|\Delta\text{RMST}| = 75.6$. Потрібне $N \approx (2.80 \times 590/75.6)^2 \approx 480$. Поточні 100 реплікацій дають потужність $\approx 25\%$ — узгоджено з CI, що включає нуль.

Калібрований clique $k = 10$. $\sigma_\Delta \approx 450$, $|\Delta\text{RMST}| = 127.9$. Потрібне $N \approx (2.80 \times 450/127.9)^2 \approx 97$. 100 реплікацій якраз достатньо; CI виключає нуль.

CE-01 (paired). Спарювання реплікацій (той самий seed) драматично зменшує σ_Δ (between-run дисперсія усунена). 100 парних реплікацій достатньо для всіх чотирьох контрастів із $|\Delta\text{RMST}| \geq 160$.

Практичне правило: для chain benchmark без спарювання використовуйте щонайменше $N = 300$ реплікацій, коли $|\Delta\text{RMST}| < 100$.

8 Підсумок

1. **RMST та** ΔRMST — коректні первинні метрики. Вони обробляють censoring, прямо пов'язані з нерівністю Jensen, і мають добре зрозумілі статистичні властивості.

2. **Conditional mean/median** (лише завершені прогони) вносить selection bias щоразу, коли completion rates відрізняються. Воно може показати неправильний знак (напр., clique baseline: conditional median $= +70.8$, тоді як RMST $= -75.6$).

3. **Відстань** $\mathbf{W}_1$ валідна для порівняння форми розподілу, коли обидві моделі мають майже-100% completion. Використовуйте її поряд із RMST, а не замість нього.

4. **Поточкові графіки** $I_{\text{tot}}(t)$ відображають phase noise, а не похибку апроксимації. Корисні для візуального контексту (особливо sparse case), але не для квантифікації bias.

5. **Per-hop парна похибка** δ_i — найчутливіший діагностичний засіб: вона усуває between-run дисперсію, використовуючи paired seeds. Інтерпретуйте значення останнього шару обережно через censoring повільних прогонів Micro.

6. **100 реплікацій** недостатньо для clique baseline ($k = 5$), щоб виявити Jensen bias на 5% значущості. Потрібно ≈ 400–500 реплікацій або paired seeds.